

ESTRELLAS	PROVEEDORES	TOKENS/MES	ESTRATEGIAS
45.877	290	~1.530 M	19

DEJA DE PARARTE EN EL LIMITE

La guia completa de OmniRoute: que es, como se monta, los 17 proveedores que su propia documentacion te pide revisar, las 19 estrategias de ruteo y la compresion que ahorra hasta 89% de tokens. Con la zona honesta de lo que esto **no** hace.

LO QUE VAS A ENCONTRAR

SECCION	CONTENIDO
SECCION 1	Que es realmente: un proceso local, no un servicio
SECCION 2	Instalacion completa: npm, Docker, pnpm, AUR, Nix
SECCION 3	Los 17 con nombre y apellido
SECCION 4	Las 19 estrategias de ruteo
SECCION 5	La compresion: 12 motores, de 15% a 95%
CIERRE	Que cambia para ti + zona honesta

CONTEXTO

DE DONDE SALE ESTO

OmniRoute lo publica diegosouzapw en GitHub. No es de Anthropic ni de ningun laboratorio: es un proyecto de comunidad con licencia MIT. Los numeros de esta guia salen de la API de GitHub, del registro de npm y de la documentacion del propio repo, no de su landing.

LA FICHA VERIFICABLE

Repositorio	github.com/diegosouzapw/OmniRoute
Estrellas / forks	45.877 / 6.166
Licencia	MIT (codigo abierto, uso comercial permitido)
Paquete npm	omniroute v3.8.49
Descargas npm	244.402 en el ultimo mes
Contribuidores	Mas de 500
Compatible con	Claude Code, Codex, Cursor, Cline, Copilot

El dato que mas dice de un proyecto: la cifra de tokens bajo dos veces por decision propia. De ~1.940 millones a ~1.530, corrigiendo conteos inflados. Un repo que se baja sus propios numeros es raro y es buena senal.

SECCION 1

QUE ES REALMENTE

Un gateway es un proceso que corre en **tu** maquina y se pone en medio: Claude Code le habla a el, y el decide a que proveedor mandarle cada mensaje. No sube tu codigo a ningun servidor del proyecto. Si lo apagas, todo vuelve a la normalidad.

- Una sola URL local (puerto 20128) para 290 proveedores y 516 modelos.
- Cuando un proveedor se queda sin cuota, el gateway salta al siguiente solo.
- Tres capas de resiliencia independientes: si una falla, la otra sostiene.
- Panel web propio para ver cuota gastada y cuota restante en vivo.
- Habla el protocolo de Anthropic y el de OpenAI: por eso Claude Code no nota nada.

LA PARTE QUE IMPORTA

Recien instalado ya funciona sin que pongas una sola clave, porque trae proveedores abiertos conectados de fabrica. Puedes probarlo entero antes de conectar ninguna cuenta tuya.

SECCION 2

INSTALACION COMPLETA

ELIGE UNA - NO HACEN FALTA LAS CINCO

```
# npm (la mas simple, la que recomiendo)
npm install -g omniroute@latest && omniroute

# Docker (aislado, sobrevive reinicios)
docker run -d --name omniroute --restart unless-stopped \
  -p 127.0.0.1:20128:20128 -v omniroute-data:/app/data \
  diegosouzapw/omniroute:latest

# pnpm
pnpm add -g omniroute@latest --allow-build=better-sqlite3

# Arch Linux (AUR)
yay -S omniroute-bin && systemctl --user enable --now omniroute

# desde el codigo fuente
cp .env.example .env && npm install && PORT=20128 npm run dev
```

Hay tambien app de escritorio (Electron) y version PWA si prefieres no vivir en la terminal. Para desinstalar: **npm run uninstall:full** o borrar el contenedor.

SECCION 3

LOS 17 CON NOMBRE Y APELLIDO

Esta es la tabla que casi nadie menciona. El repo la publica en docs/reference/FREE_TIERS.md bajo el titulo **Caution**: proveedores cuyos terminos traen clausulas de uso personal o anti-proxy. Su acceso libre es real, pero el contrato no contempla que los uses a traves de un intermediario.

NO LOS ENCIENDAS SIN LEER SUS TERMINOS		
agy	(Google Antigravity)	modal
ai21		muse-spark-web (Meta)
amazon-q	(descontinuado)	nlpccloud
blackbox		opencode
coze		qwen-web
duckduckgo-web		t3-web
featherless-ai		iflytek / sparkdesk
fireworks		kiro
friendliai		

El riesgo real no es legal: es que pierdas **esa** cuenta. Y la lista se reaudita cada dos semanas, asi que vuelve a mirarla antes de encender nada nuevo.

SECCION 4

LAS 19 ESTRATEGIAS DE RUTEO

Un **combo** es una cadena de modelos. Si uno se queda sin cuota, falla o se encarece, la cadena se desliza al siguiente sin que tu hagas nada. Estas son las 19 formas de decidir el orden:

MEZCLABLES POR PASO DEL COMBO

1 priority	ordenada: agota cada uno antes del siguiente
2 fill-first	llena la cuota de cada objetivo por completo
3 weighted	azar ponderado por peso que tu asignas
4 round-robin	rota en orden
5 p2c	balanceo por potencia de dos opciones
6 least-used	el de menor carga actual
7 random	azar uniforme, sin repetir
8 strict-random	azar puro, permite repetir
9 cost-optimized	el mas barato segun precio en vivo
10 headroom	el que mas cuota le quede
11 reset-window	el que reinicie su cuota antes
12 reset-aware	ordena por tiempo de reinicio
13 context-relay	pasa el contexto entre varios (charlas largas)
14 context-optimized	el que mejor encaje con tu contexto
15 cache-optimized	fija el prefijo al mismo sitio (mas cache)
16 lkgp	se queda pegado al ultimo que funciona
17 auto	puntua 12 factores en vivo
18 fusion	varios responden y un juez sintetiza
19 pipeline	encadena: la salida de uno alimenta al otro

Si no quieres pensar en esto: usa **auto** y ya. Las variantes auto/coding, auto/fast, auto/cheap y auto/offline cubren el 90% de los casos.

SECCION 5

LA COMPRESION

Esta es la parte que menos se entiende y mas ahorra. Cada peticion pasa por una tuberia de 12 motores que recortan el contexto antes de mandarlo. El combo por defecto encadena dos (RTK y Caveman) y sus ahorros se multiplican.

Ahorro combinado	78,4% a 94,6% - promedio ~89%
Modo Lite	~15% - seguro, siempre encendido
Modo Standard	~30% - para el dia a dia
Modo Aggressive	~50% - sesiones largas con muchas herramientas
Siempre intacto	Bloques de codigo, URLs y datos estructurados

- Session-Dedup: borra lo que ya se dijo en turnos anteriores.
- Relevance: puntua frases contra tu ultima pregunta y tira el resto.
- LLMingua-2: poda semantica con un modelo pequeno, sin tocar codigo.
- OmniGlyph: experimental, manda el contexto como imagen. Opcional.

QUE CAMBIA

PARA TI, SEGUN COMO TRABAJAS

Programas a diario	Es para ti: recuperas las horas muertas del limite
Sesiones largas	Enciende Aggressive: es donde mas se nota
Uso ocasional	No lo necesitas. No instales nada
Codigo de terceros	Usa Docker: no toca tu sistema
Equipo o empresa	Revisa antes los terminos de TUS cuentas
Primer mes	Hasta ~2.150 M con los creditos de registro

EL ORDEN QUE YO SEGUIRIA

- Instalar con npm y probar el modelo auto sin conectar ninguna cuenta.
- Mirar la tabla Caution y decidir cuales NO vas a encender.
- Encender dos o tres proveedores limpios y dejarlo una semana.
- Recien ahi tocar estrategias y modos de compresion.

ZONA HONESTA

LO QUE ESTO NO HACE

- No elimina el limite: lo reparte entre mas sitios. Sigue habiendo techo.
- Los 10.000 millones de tokens que veras por ahi NO son reales: el propio repo pide que no se publique esa cifra porque no es una garantia.
- Los modelos abiertos no son Claude. Para razonamiento fino vas a notar la caida.
- 17 proveedores tienen clausulas que su documentacion te pide revisar.
- Las cifras se mueven en las dos direcciones: un proveedor cierra su capa libre y el numero baja. Se reaudita cada dos semanas.
- Es software de comunidad, no un producto con soporte. Si se rompe, es tu problema.

LO QUE NO ESTOY AFIRMANDO

Que sea seguro para uso corporativo, que Anthropic lo respalde (no lo hace: es un proyecto de terceros), ni que los 290 proveedores sean intercambiables. No lo son.

CIERRE

EL RESUMEN EN UNA PAGINA

Si programas todos los días y vives chocando con el límite, esto te devuelve las horas que hoy pierdes esperando. Si le escribes a Claude un par de veces al día, cierra este PDF: no lo necesitas y montarlo te va a costar más de lo que te ahorra.

ESTO NO TE HACE MEJOR PROGRAMADOR. TE QUITA EL MURO.

Si quieres la hoja de configuración segura -- el paso a paso para dejarlo corriendo sin ninguno de los 17 -- comenta RUTA en el reel y te la mando.