

PROVEEDORES	CON AVISO ToS	TOKENS/MES	LICENCIA
290	17	~1.530 M	MIT

LA RUTA SEGURA DE OMNIROUTE

OmniRoute conecta Claude Code con 290 proveedores de modelos y agrega ~1.530 millones de tokens documentados al mes. Pero su propia documentacion publica una tabla de aviso: 17 proveedores tienen clausulas de uso personal o anti-proxy. Esta hoja te deja el gateway corriendo **sin ninguno de esos 17**.

LO QUE ESTA HOJA TE DEVUELVE

SECCION	CONTENIDO
PASO 0	Que necesitas antes de instalar nada
PASO 1	Instalar y arrancar el gateway en el puerto 20128
PASO 2	Apuntar Claude Code al gateway (variables de entorno)
PASO 3	Encender solo los proveedores limpios y elegir el modo auto

PASO 0

ANTES DE INSTALAR

Esto corre en tu maquina. No es un servicio de nadie: es un proceso local que se pone entre Claude Code y los proveedores. Si algo falla, lo apagas y Claude Code vuelve a funcionar como siempre.

- Node 20 o superior instalado (verifica con `node --version`).
- Claude Code ya funcionando en tu terminal.
- El puerto 20128 libre: es el que usa el gateway por defecto.
- Cinco minutos. No necesitas tarjeta ni cuenta en ningun lado para arrancar.

LA REGLA QUE NO SE ROMPE

Nunca enciendes	Un proveedor de la tabla de aviso (los 17)
Riesgo real	Perder esa cuenta, no una sancion legal
Donde se verifica	docs/reference/FREE_TIERS.md del repo
Se reaudita	Cada dos semanas: la lista cambia

PASO 1

INSTALAR Y ARRANCAR

TERMINAL - COPIA TODO ESTO

```
# 1. instalar el gateway (paquete npm oficial)
npm install -g omniroute@latest

# 2. arrancarlo (queda escuchando en el puerto 20128)
omniroute

# 3. comprobar que responde, sin configurar una sola clave
curl http://localhost:20128/v1/chat/completions \
  -H 'Content-Type: application/json' \
  -d '{"model": "auto", "messages": [
    {"role": "user", "content": "Hola"}]}'
```

Si el paso 3 te devuelve una respuesta, ya esta: el gateway trae proveedores abiertos conectados de fabrica y el modelo **auto** elige por ti. Todavia no has tocado ninguna cuenta tuya.

PASO 2

APUNTAR CLAUDE CODE AL GATEWAY

VARIABLES DE ENTORNO - EJEMPLO LLENADO

```
# en tu ~/.zshrc (o ~/.bashrc), y abres una terminal nueva
export ANTHROPIC_BASE_URL=http://localhost:20128
export ANTHROPIC_AUTH_TOKEN=omniroute-local

# elegir como reparte el trabajo:
#   auto           equilibrado (se queda en el ultimo que funciona)
#   auto/coding    prioriza calidad para generar codigo
#   auto/fast      prioriza latencia baja
#   auto/cheap     prioriza el mas barato por token
#   auto/offline   prioriza el que tenga mas cuota libre
```

Para volver atras, borras las dos variables y abres una terminal nueva. Claude Code vuelve a hablar directo con Anthropic. Es reversible en diez segundos.

PASO 3

ENCENDER SOLO LO LIMPIO

En el panel del gateway (<http://localhost:20128>) entra a la pagina de proveedores. Enciende de esta lista, que NO aparece en la tabla de aviso:

- Kilo Code y Requesty: gratuitos de forma permanente, sin tope de tokens.
- Z.AI GLM (GLM-4.7 y 4.5-Flash) y Qoder AI (Qwen3-Max, Kimi-K2).
- Cerebras: 1 millon de tokens al dia, de los mas rapidos del grupo.
- OpenRouter con sus modelos :free, para tapar huecos puntuales.

Deja apagado todo lo que dude. El gateway rutea con lo que este encendido: menos proveedores no lo rompe, solo le da menos sitios a donde saltar.

EL LIMITE NO SE ELIMINA. SE REPARTE.

Esta hoja te deja corriendo. Si quieres la guia completa -- los 17 con nombre y apellido, las 19 estrategias de ruteo y la compresion que ahorra hasta 89% de tokens -- comenta LIMITE en el reel y te la mando.